

High-Dimensional Geometric Analysis of Seed Sensitivity in MoE Semantic Watermarking

Anonymous Authors¹

混合专家模型与语义哈希水印 中的随机种子敏感性

Abstract

基于混合专家模型 (Mixture-of-Experts, MoE) 的大语言模型 (LLM) 已在工业界和学术界广泛部署, 水印技术被视为区分机器生成文本与人类创作文本的关键工具。以 SemHash 为代表的语义水印方法利用局部敏感哈希 (Locality-Sensitive Hashing, LSH) 在嵌入空间中构造“红/绿”区域, 在理论上具有较强的改写鲁棒性。然而, 实际系统表明此类方法在 MoE LLM 上呈现出极端的随机种子敏感性: 极少数种子可达到 SOTA 生成质量和检测性能, 而大部分随机初始化会导致困惑度爆炸或检测失效。与其将种子视作单纯超参数, 本文从高维几何和流形学习的角度系统刻画这一现象。我们指出: LLM 嵌入空间呈现强烈的各向异性 (“锥体效应”), 而标准 LSH 预设的各向同性假设在此完全失效; 随机超平面在高维各向异性锥体上极大概率出现“区域坍塌”, 要么将整个语义簇标记为绿、无法注入熵, 要么整体标记为红、迫使模型生成语义崩溃的 Token。在 MoE 架构下, 水印诱导的语义偏移进一步干扰专家路由, 放大了种子敏感性。为刻画和缓解该问题, 我们提出一套基于语义簇分割熵、Logits 分布 Wasserstein 距离与 PCA 对齐度的“几何质量”指标, 并给出白化变换、PCA 对齐 LSH 与基于聚类的非线性划分等数据依赖方案。本文的结论是: 种子敏感性不是偶然噪声, 而是“各向异性流形 + 各向同性投影”几何错配的必然结果, 解决路径应从被动选种转向主动重构几何和投影方向。

¹Anonymous Institution, Anonymous City, Anonymous Region, Anonymous Country. **AUTHORERR: Missing \icmlcorrespondingauthor.**

Preliminary work. Under review by the International Conference on Machine Learning (ICML). Do not distribute.

1. 引言: 语义水印的几何不稳定性

大语言模型 (LLM) 的生成能力快速提升, 使得内容溯源与版权保护问题日益突出。水印 (Watermarking) 通过在生成过程中注入可检测但难以察觉的统计信号, 被视为当前最具可行性的治理手段之一。经典的 Token 级水印 (如 green-list 方案) 通过伪随机函数将词表划分为“绿表/红表”, 在生成时对绿表 Token 加性偏置, 并在检测阶段进行统计显著性检验。该类方法计算开销低、训练开箱即用, 却对保持语义不变的改写攻击 (Paraphrase Attack) 极为脆弱。

为应对这一缺陷, 近期工作转向语义级水印。典型地, SemStamp/SemHash 通过外部句向量编码器将文本映射到 \mathbb{R}^d 中连续语义嵌入, 再使用 LSH 将连续空间量化为离散哈希桶, 用以驱动绿表选择。在理想化模型中, 若语义嵌入在单位超球上各向同性分布, 则随机超平面可以稳定地按角度划分语义邻域, 从而在语义邻近 Token 之间实现“低损失替换”。

MoE 场景下的工程痛点。 当上述方法被部署到 MoE LLM (如 Mixtral、DeepSeek MoE、Qianwen MoE) 时, 实践中暴露出一个严重问题: 水印性能对随机种子 (决定 LSH 超平面) 呈现极端敏感性。少数“幸运种子”可以在几乎不损伤生成质量的前提下实现高检测率, 而大部分随机种子要么几乎检测不到水印, 要么显著拉高困惑度、产生语义错乱输出。

本文尝试回答: 这种种子敏感性是偶然现象, 还是高维几何结构的必然结果? 如果是后者, 我们是否可以在训练前、部署前对种子进行几何质量评估与筛选, 甚至通过重新设计哈希空间来消除此类敏感性?

1.1. MoE 架构下的特殊性: 路由几何的放大效应

混合专家模型 (MoE) 在每一层包含多个专家网络和一个路由门控网络。对于给定 Token 隐状态 \mathbf{h}_t , 路由器计算专家权重 $\mathbf{r}_t \in \mathbb{R}^E$ 并选择 top- k 专家进行激活。该机制一方面带来参数高效扩展, 另一方面引入了高度结构化的几何边界: 路由决策本质上由一系列高维超平面刻画。

当在 MoE 上叠加 SemHash 风格的水印平面时, 系统中同时存在两套几何划分:

- 内生的 路由平面，决定哪些专家被激活；
- 外加的 水印平面，决定哪些 Token 被视为“绿表候选”。

若水印平面在语义空间中强行抑制了原本高概率的候选 Token，将导致 h_t 发生非局部偏移，使得路由器激活与上下文语义不匹配的专家。我们将这种现象称为 路由错位 (*Routing Misalignment*)。在长上下文生成中，这种错位具有级联效应：一处水印诱导的错误选择可在后续层层放大，导致整体语义漂移。

因此，MoE 场景下的种子敏感性不仅反映在单步 Logits 分布被扰动，更体现在路由轨迹这一复杂几何对象被扭曲。

1.2. 本文贡献

围绕上述现象，本文从高维几何与流形学习的角度提出以下贡献：

1. 几何机理刻画：揭示 LLM 嵌入空间中“锥体效应”与 LSH 各向同性假设之间的根本矛盾，给出随机超平面在各向异性锥体上高概率导致“区域坍塌”的几何推导。
2. 语义碎片化分析：建立语义聚类与 Logits 选择的几何模型，解释糟糕种子如何通过切断高概率语义簇而迫使模型选择语义噪声 Token。
3. 指标体系设计：提出三类可在部署前计算的种子质量指标：语义簇分割熵、Logits 分布的 Wasserstein 距离以及投影方差/PCA 对齐度。
4. 几何修正方案：讨论白化变换、PCA 对齐 LSH 以及基于质心的非线性划分作为缓解种子敏感性的技术路径。

2. 高维语义空间的几何特性

2.1. 理想各向同性与现实各向异性

经典 LSH 理论多基于如下假设：数据点 $x \in \mathbb{R}^d$ 在单位超球 \mathbb{S}^{d-1} 上各向同性分布。以 SimHash 为例，在该假设下，两向量夹角 $\theta(x, y)$ 与哈希碰撞概率近似线性关系：

$$\mathbb{P}[h(x) = h(y)] = 1 - \frac{\theta(x, y)}{\pi}. \quad (1)$$

随机投影向量 $r \sim \mathcal{N}(0, I_d)$ 被视为在超球上均匀采样，其对应的超平面以“公平”的方式切割数据。

然而，大量实证工作表明：BERT、GPT、Mixtral 等模型的上下文嵌入远非各向同性，而是呈现显著的各向异性 (*Anisotropy*)。记嵌入矩阵为 $X \in \mathbb{R}^{N \times d}$ ，协方差为

$$\Sigma = \frac{1}{N} X^\top X. \quad (2)$$

在各向异性场景下，特征值谱表现为极少数主成分 $\lambda_1, \lambda_2, \dots$ 占据绝大多数能量，其余特征值快速衰减。这意味着数据实际集中在一个远低于 d 维的流形上，并且该流形具有显著朝向，可视为被“压缩”在一个开口角极小的锥体 \mathcal{K} 内。

更直观地，对任意两个随机词向量 u, v ，经验上有

$$\mathbb{E}[\cos(u, v)] \approx 1 - \Delta, \quad \Delta \ll 1, \quad (3)$$

与各向同性高维空间“随机向量近似正交”的结论相反。

2.2. 随机投影在锥体分布下的失效

考虑法向量 $r \sim \mathcal{N}(0, I_d)$ 对应的超平面 H_r 与数据锥体 \mathcal{K} 的相互位置。根据高维测度集中的经典结果， r 与锥体主轴方向 μ 的夹角 ϕ 高度集中于 $\pi/2$ 附近，即大部分随机方向与 μ 近似正交。

然而，要让 H_r 有效地对数据产生“划分”作用，平面必须穿过锥体内部；否则所有样本将全部落在同侧。若锥体张角为 $\alpha \ll 1$ ，则只有当 r 落入一个极窄的“赤道带”时，平面才会与锥体发生非平凡交集。由此可见：

- 绝大多数随机种子对应的平面 完全掠过锥体，导致锥体内所有点同侧。
- 少数“幸运种子”恰好对应穿过锥体的平面，才能实现有效二分。

区域坍塌 (**Region Collapse**)。在极端各向异性下，随机平面对数据的典型行为可概括为两种情形：

情形 A：失效 超平面完全位于锥体一侧。此时所有语义合理的候选 Token 被统一标记为绿或红：

- 若全为绿，则水印对生成无约束，检测信号消失；
- 若全为红，则模型被迫在语义无关的尾部分布中寻找“可用”Token，生成质量崩溃。

情形 B：有效 超平面侥幸穿过锥体，在局部实现了非平凡切割，从而允许在语义邻近 Token 间实施偏置。

MoE 场景下实验观察到的“好种子极少、坏种子占绝大多数”，正是情形 B 占比随维度与各向异性程度指数级下降的体现。

3. 语义碎片化与 Logits 选择

用户关注的第一个问题是：糟糕的种子如何从几何上破坏语义聚类，并在 Logits 层面推动模型选择语义噪声 Token。

3.1. 语义聚类的几何刻画

在 next-token 预测中, 给定上下文 C , 模型输出 Logits 向量 \mathbf{z} , 高概率 Token 往往集中在一个或多个紧密簇中。例如对于“The cat sat on the ...”, 最高概率 Token 集合

$$\mathcal{T}_{\text{top}} = \{\text{mat, rug, floor, sofa}\} \quad (4)$$

在嵌入空间中形成一个半径极小的超球 $\mathcal{B}_\epsilon(c)$, 其中 c 为簇中心、 ϵ 很小。

3.2. 碎片化切割与强制降级

设由种子 S 决定的超平面 H_S 将空间划分为水印“绿区” V_G 与“红区” V_R 。理想情况下, H_S 对每个语义簇都实现近似 50%/50% 切分, 使得至少存在若干同义词落在绿区中, 模型可在低语义代价下替换 Token。但在锥体背景与随机投影机制下, 更典型的却是以下两种极端:

- 整个高质量簇 $\mathcal{B}_\epsilon(c)$ 被压入红区, 绿区只包含语义无关或低概率 Token;
- 整个簇进入绿区, 无法注入任何水印信息。

记最优 Token 为 t^* , 其 Logit 为 z_{max} , 次优同义词为 t' , Logit 为 $z_{\text{sub}} \approx z_{\text{max}}$ 。对绿区 Token 施加偏置 $\delta > 0$ 后, 生成概率为

$$P(t) \propto \exp(z_t + \delta \cdot \mathbb{I}[t \in V_G]). \quad (5)$$

当 $t^* \in V_R$ 且所有高质量同义词均被切到红区时, 模型被迫在 V_G 内选择 Logit 最大的 t_{noise} , 其原始 Logit $z_{\text{noise}} \ll z_{\text{max}}$ 。若

$$z_{\text{noise}} + \delta > z_{\text{max}}, \quad (6)$$

则模型输出 t_{noise} , 表现为明显的语义漂移甚至胡言乱语。我们将此过程称为 强制降级 (*Forced Downgrade*)。

3.3. 低熵任务中的区域坍塌

在低熵生成任务 (例如结构化摘要、事实问答) 中, 模型的高质量输出空间往往近似退化为一个极小邻域甚至“点”。当 $\epsilon \rightarrow 0$ 时, 任意超平面对该“点簇”的切割要么是“全进全出”, 要么几乎不产生有效边界。此时 SemHash 试图在该簇内部注入熵的企图注定失败: 要么完全无法检测, 要么在某一关键步整体封锁高质量空间, 引发灾难性生成错误。

4. 各向异性与随机投影的低效性

4.1. 投影方差的极度不均衡

LSH 的区分能力依赖于投影值

$$y = r^\top x \quad (7)$$

在数据分布上的方差:

$$\text{Var}(y) = r^\top \Sigma r. \quad (8)$$

在强各向异性下, Σ 的能量集中在前 k 个主成分 u_1, \dots, u_k 上。高维几何告诉我们: 对随机向量 r , 其在任一固定方向上的投影 $\langle r, u_i \rangle$ 期望极小。因此, 对绝大多数种子而言, $\text{Var}(y)$ 接近 0, 即“切了空气而非数据”。

类比三维“黄瓜”: 有效的水印平面应沿长轴方向切割, 而随机平面大概率平行于长轴且远离黄瓜本体, 或仅掠过其边缘。

4.2. 碰撞概率退化与辨识度丧失

在各向异性锥体中, 任意两个有效语义向量 x_1, x_2 的夹角 θ 极小 (例如 $\theta < 15^\circ$)。由 SimHash 碰撞关系可得

$$\mathbb{P}[h(x_1) = h(x_2)] = 1 - \frac{\theta}{\pi} \approx 1, \quad (9)$$

意味着对绝大部分种子, 所有语义相关向量被哈希到相同桶中。这带来两方面后果:

- 辨识度丧失: 水印难以在不同语义状态之间制造差异;
- 鲁棒性两极化: 若该桶被标记为绿, 则极难检测; 若被标记为红, 则极易毁坏生成。

因此, 在 LLM 的各向异性嵌入空间中, 未经修正的随机投影在理论上注定效率低下且不稳定。

5. 量化种子几何质量的指标体系

为了在部署前筛选种子, 我们提出三类互补的“几何质量”指标。

5.1. 语义簇分割熵: 刻画碎片化程度

首先在一个校准数据集上, 用无水印模型构造词表语义聚类: 对 Token 嵌入做 k-means, 得到 K 个簇 C_1, \dots, C_K 。对给定种子, 计算全词表红绿划分 V_G, V_R 。对每个簇 C_i , 定义绿表比例

$$r_i = \frac{|C_i \cap V_G|}{|C_i|}. \quad (10)$$

理想情况下 $r_i \approx 0.5$ 。我们定义分割熵得分为

$$\text{Score}_{\text{split}} = 1 - \frac{1}{K} \sum_{i=1}^K (2|r_i - 0.5|)^2. \quad (11)$$

当所有簇被整体压入绿表或红表时, $r_i \in \{0, 1\}$, 得分趋近 0, 意味着严重区域坍塌; 得分越接近 1, 说明切分越均匀, 语义碎片化风险越低。

5.2. Logits 分布的 Wasserstein 距离：刻画“推土机距离”

考虑单步生成中，原始 Softmax 分布 P 与施加水印偏置后的分布 Q 。令 $D_{ij} = \|\text{emb}(i) - \text{emb}(j)\|_2$ 表示 Token 之间的语义距离矩阵。则 Wasserstein-1 距离为

$$W_1(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|_2], \quad (12)$$

其中 $\Pi(P, Q)$ 为所有以 P 与 Q 为边缘分布的联合分布集合。直观上， W_1 度量“将概率质量从 P 推到 Q 需要搬运的语义距离总量”。

- 好的种子使 W_1 保持较小，仅在同义词等近邻 Token 间重新分配概率；
- 坏种子导致 W_1 显著增大，说明概率质量被迫迁移到语义遥远的 Token 上。

在实践中，可在代表性任务与步长上估计 W_1 的期望或分位数，将其作为种子筛选的硬约束。

5.3. 投影方差与 PCA 对齐度：刻画各向异性适应度

在校准集上收集嵌入矩阵 X ，对给定种子对应的投影向量 r ，计算

$$h = Xr, \quad \sigma_{\text{proj}}^2 = \text{Var}(h). \quad (13)$$

若 σ_{proj}^2 极小，说明 r 近似垂直于数据流形，平面主要切到“空旷区域”；反之，较大的方差意味着平面沿着数据主要变化方向切割，更有可能穿过锥体核心。

进一步，可利用 PCA 主成分 u_1, \dots, u_k 定义

$$\text{Align}(r) = \sum_{i=1}^k \cos^2(r, u_i), \quad (14)$$

该值越大，说明种子越“对齐”于高能量方向，从几何上更有希望获得稳定且高熵的哈希划分。

6. 解决种子敏感性的几何方案

基于前述分析，我们认为解决种子敏感性的关键不是“试出一个好种子”，而是重构数据几何或投影机制，使大部分种子都变得可用。

6.1. 白化变换：修正嵌入几何

在进行 LSH 之前，对嵌入向量进行白化：

$$\tilde{x} = W(x - \mu), \quad W = \Sigma^{-1/2}, \quad (15)$$

其中 μ 与 Σ 分别为均值与协方差估计。白化操作将原本高度各向异性的锥体拉伸为近似各向同性的球体。在此新空间中，随机投影重新符合经典 LSH 假设，使种子敏感性大幅降低。代价主要为一次性离线估计 W 和在线前向中的轻量线性变换。

6.2. PCA 对齐的 LSH：修正投影方向

另一条路径是放弃完全均匀的随机 r ，而从数据主成分中抽取投影向量。具体地，在校准集上对嵌入做 PCA，取前 k 个主成分 u_1, \dots, u_k 作为 LSH 的法向量族。这种 PCA-LSH 方案保证每个超平面都沿着数据方差最大的方向切割，从而必然与锥体核心发生交集，避免“切空气”。

在此基础上，可对主成分进一步做随机旋转或正交变换，以在保证高方差的前提下引入足够的密钥空间。

6.3. 基于质心的非线性划分：拥抱数据拓扑

更激进的策略是完全放弃线性超平面，将水印划分建立在数据驱动的聚类结构上。例如 k-SemStamp 提出：

1. 对语义嵌入做 k-means 聚类，获得簇中心 $\{c_j\}_{j=1}^K$ ；
2. 使用 Voronoi 划分定义语义单元，再随机给簇分配“红/绿”标签。

由于聚类本身追求簇内紧致性、簇间分离度，该方案天然避免了在簇内部“硬切割”，从根本上消解语义碎片化问题。其缺点是需要离线聚类和在线最近质心查询。

7. 结论

本文从高维几何和流形学习的视角，对 MoE LLM 中基于 SemHash 的语义水印所呈现的极端随机种子敏感性进行了系统分析。我们的结论可以概括为：

- LLM 嵌入空间的“锥体效应”与 LSH 的各向同性假设存在根本冲突，使得随机超平面在高维中高概率导致“区域坍塌”，要么无效、要么毁灭性破坏生成；
- 语义碎片化源于超平面正交于语义流形主轴，切断高概率语义簇并强制模型在尾部分布中选取噪声 Token，在 MoE 场景下还会诱导路由错位；
- 通过语义簇分割熵、Wasserstein 距离与投影方差 / PCA 对齐度等指标，可以在部署前对种子几何质量进行定量评估；
- 真正可行的解决路径应从“试运气选种”转向“重构几何与投影”：通过嵌入白化、PCA 对齐 LSH 或基于聚类的非线性划分，使大多数种子在数学上都具有稳定且可解释的行为。

从更宏观的角度看，MoE 水印中的种子敏感性问题并非孤立现象，而是“低维流形数据 + 高维随机机制”组合下常见的几何陷阱。我们希望本文的分析能够为后续设计鲁棒、可解释且几何自洽的水印方案提供理论基线。

致谢

本工作在匿名评审阶段暂不列出具体的致谢对象。

影响声明

本研究聚焦于面向大语言模型的水印技术，其潜在影响具有双刃性。一方面，鲁棒水印有助于内容溯源、版权保护与错误信息检测；另一方面，不当使用也可能带来隐私、审查与滥用风险。我们鼓励在公开透明的前提下部署水印系统，结合法律与伦理框架，避免将技术用于牺牲用户自主权的场景。

References